

УНИВЕРСИТЕТ ИННОПОЛИС

Бакалавриат по направлению «Компьютерные науки»

Аннотация к выпускной квалификационной работе

**ViKi: кинематическая имитация на основе компьютерного зрения
для объектно-центричного ретаргетинга демонстраций
манипуляции человека на роботизированные манипуляторы**

Автор: **Артём [Фамилия]**

Научный руководитель: **[ФИО]**

Группа: **[группа]**

Иннополис, Россия

2026

Оглавление

1	Постановка задачи и актуальность	2
1.1	Предметная область	2
1.2	Проблема	3
1.3	Научный пробел	3
1.4	Исследовательские вопросы и гипотезы	4
2	Обзор литературы	6
2.1	Представление кисти человека	6
2.2	Формулировки ретаргетинга	7
2.3	Представление задачи	7
2.4	Калибровка, слияние и синхронизация мультикамерного RGB-D рига	8
2.5	Позиционирование предлагаемой системы	9
3	Предлагаемое решение	10
3.1	Общая структура пайплайна	10
3.2	Калибровка и синхронизация	10
3.3	Слияние со взвешиванием по достоверности	11
3.4	Ретаргетинг как единый функционал стоимости	11
3.5	Валидация воспроизведением	12
4	Реализация, результаты и обсуждение	13
4.1	Реализация	13
4.2	Экспериментальная установка	13
4.3	Метрики	14
4.4	Результаты	14
4.5	Декомпозиция ошибки	14
4.6	Ограничения	15
5	Выводы	16

Глава 1

Постановка задачи и актуальность

1.1. Предметная область

Обучение роботизированных манипуляторов методом имитации (imitation learning) стало практичным подходом к решению задач манипуляции благодаря появлению визуомоторных политик, таких как Action Chunking Transformer (ACT) и Diffusion Policy. Качество и обобщающая способность таких политик напрямую зависят от объёма и качества обучающих демонстраций.

Доминирующим способом получения демонстраций сегодня является телеоперация: человек-оператор проводит робота по траектории выполнения задачи, а состояния суставов и видеопотоки записываются. Основное преимущество телеоперации в том, что метки действий по построению исполнимы на целевом эмбодименте. Однако у подхода есть структурные недостатки. Каждый эпизод требует времени оператора в режиме реального времени; необходимое оборудование — VR-контроллер, экзоскелет или устройство с силовой обратной связью — дорого и специфично для конкретного эмбодимента; наконец, записанное движение определяется не столько самой задачей, сколько задержками и эргономикой интерфейса управления.

Пассивная запись демонстраций, при которой человек выполняет задачу голыми руками без какого-либо интерфейса, обращает этот компромисс. Сбор данных становится дешёвым, быстрым и естественным: демонстратор успевает записать десятки эпизодов за время, необходимое телеоператору на один. Утрачивается при этом ровно то свойство, которое телеоперация гарантирует: отсутствуют метки действий, а кинематика руки человека не соответствует кинематике роботизированного манипулятора. Преодоление этого несоответствия и составляет задачу ретаргетинга, которой посвящена настоящая работа.

1.2. Проблема

Пассивный захват удешевляет сбор данных, но порождает наблюдения, а не действия. Преобразование наблюдаемой траектории кисти человека в траекторию суставов робота, которая одновременно (i) воспроизводит значимое для задачи движение, (ii) достаточно гладка для имитации политикой и (iii) физически исполнима на целевом манипуляторе, представляет собой недоопределённую задачу, осложнённую шумом восприятия.

Доминируют два режима отказа.

Усиление шума через кинематическую цепь. Монокулярные или нейросетевые оценки глубины ключевых точек кисти зашумлены на сантиметровом масштабе. Обратная задача кинематики нелинейна, поэтому ограниченное возмущение в пространстве задачи может отобразиться в неограниченное отклонение в пространстве суставов вблизи сингулярностей. Широко применяемый ответ — низкочастотная фильтрация наблюдаемой траектории до решения обратной кинематики с последующей фильтрацией траектории суставов — проблему не решает. Предварительная фильтрация применяется в пространстве задачи, тогда как гладкость требуется в пространстве суставов, и вдобавок она удаляет истинное высокочастотное содержание задачи вместе с шумом. Именно эта схема «мусор на входе — мусор на выходе» и мотивирует настоящую работу.

Представленческая зависимость. Траектория, записанная как абсолютная последовательность положений в системе координат камеры или мира, привязана к конкретной пространственной раскладке сеанса записи. Если объект переместить, траектория окажется неверной; при смене эмбодимента — неверной иначе. Обобщается отношение между кистью и манипулируемым объектом, а не абсолютный путь кисти в пространстве.

1.3. Научный пробел

Оба режима отказа имеют известные решения, но эти решения приняты в разных, не пересекающихся сообществах.

Оптимизационный ретаргетинг, в котором точность соответствия данным, временная гладкость и ограничения на суставы формулируются как единая задача условной оптимизации по конфигурации робота, стал стандартом в системах *онлайн-телеоперации*. Каноническую форму задали AnyTeleop и связанная с ним библиотека *dex - retargeting*; на них непосредственно опираются Open-TeleVision, Bunny-VisionPro и ACE; DexFlow расширяет штраф гладкости до второго порядка. Однако во всех случаях человек остаётся в контуре управления, оптимизация выполняется на интерактивных частотах, и датасет не формируется.

Напротив, *офлайн-пайплайны*, генерирующие датасеты из пассивного видео человека, принимают объектно-центричные представления, но не единую оптимизационную постановку. ORION планирует по разреженным ключевым кадрам объекта и вовсе не выполняет покад-

ровый ретаргетинг кисти. OKAMI восстанавливает параметрическую модель тела и кисти и выполняет ретаргетинг в две развязанные стадии — варпинг референсной траектории под новое положение объекта с последующим решением обратной кинематики, — что структурно совпадает с раскритикованной выше последовательной схемой.

Целевой анализ предшествующих работ, проведённый в рамках настоящего исследования, не выявил опубликованной системы, объединяющей одновременно: пассивный безмаркерный захват; метрически откалиброванный мультикамерный RGB-D риг; объектно-центричное плотное траекторное представление; ретаргетинг как единый функционал стоимости; экспорт датасета, готового к обучению политик; и физическое воспроизведение как этап валидации до экспорта. Ближайшие системы удовлетворяют части критериев и не удовлетворяют остальным. Таким образом, закрываемый пробел состоит не в изобретении нового оператора ретаргетинга, а в переносе устоявшейся формулировки в режим, где она не применялась, вместе с необходимой этому режиму сенсорной и валидационной инфраструктурой.

1.4. Исследовательские вопросы и гипотезы

Работа направляется одним основным исследовательским вопросом и тремя подвопросами.

ИВ. *Каким образом демонстрации манипуляции, захваченные пассивно откалиброванным мультикамерным RGB-D ригом, могут быть подвергнуты ретаргетингу на роботизированный манипулятор так, чтобы получить датасеты, пригодные для обучения визуомоторных имитационных политик?*

ИВ1. Как постановка ретаргетинга в виде единого взвешенного функционала стоимости, объединяющего член соответствия данным со взвешиванием по достоверности с штрафами на скорость и ускорение, влияет на точность и гладкость результирующих траекторий суставов по сравнению с последовательной схемой smooth-IK-smooth?

ИВ2. Какая точность оценки позы запястья достижима при взвешенном по достоверности слиянии нескольких откалиброванных RGB-D видов, привязанных к общей системе координат рабочей области по маркерной доске ChArUco, и как остаточная ошибка декомпозируется по независимым источникам?

ИВ3. В какой степени воспроизведение синтезированных траекторий на физическом манипуляторе до экспорта датасета повышает исполнимость экспортируемых данных?

Гипотезы.

Г1 (поведение). Ретаргетинг, поставленный как единый взвешенный функционал стоимости, даёт траектории суставов с меньшей ошибкой отслеживания в пространстве задачи и

большей гладкостью, чем последовательная схема smooth–IK–smooth, на одних и тех же записанных демонстрациях. Независимая переменная — формулировка ретаргетинга; зависимые — RMSE отслеживания позы запястья и спектральная длина дуги траектории суставов; популяция — записанные демонстрации ограниченного класса задач; отношение — доминирование единой формулировки по обоим мерам.

Г2 (поведение). Взвешивание члена соответствия данным по покадровой достоверности восприятия снижает ошибку отслеживания относительно равномерного взвешивания, причём снижение больше на кадрах с частичной окклюзией ключевых точек кисти.

Г3 (надёжность). Отбор траекторий по результатам физического воспроизведения до экспорта повышает долю экспортированных эпизодов, успешно исполняемых на манипуляторе.

Вопросы проверены по критериям FINER. Они *выполнимы* — оборудование, решатель и протокол оценки доступны, класс задач намеренно ограничен; *интересны* и *релевантны* сообществу робототехнического обучения, поскольку стоимость демонстраций является признанным узким местом; *новы* в установленном выше смысле переноса режима, а не нового оператора; и *этичны*, поскольку исследование не вовлекает испытуемых помимо автора и не сохраняет персональных данных.

Глава 2

Обзор литературы

2.1. Представление кисти человека

Значительная часть работ восстанавливает полную кинематику демонстратора. OKAMI сочетает SMPL-H для тела с MANO для кисти и выполняет ретаргетинг отдельно. DexCanvas строит датасет соответствий человек–робот, подгоняя MANO к данным двадцати двух инфракрасных камер захвата движения и двух RGB-D сенсоров. DexMV аналогично восстанавливает полную модель MANO вместе с позой объекта.

Полная реконструкция даёт богатое представление и необходима, когда целевым эмбодиментом является многопальцевая антропоморфная кисть. Одновременно она вносит тяжёлый перцептивный стек и дополнительный, плохо охарактеризованный источник ошибки — саму подгонку меша. Для параллельного схвата большая часть этого представленческого богатства далее отбрасывается.

Альтернатива, принятая в настоящей работе, представляет кисть как позу запястья в $SE(3)$ вместе с бинарным состоянием захвата. Это не уступка ради вычислительной простоты, а представление, используемое магистральным направлением современных систем телеоперации. Open-TeleVision отображает позу запястья оператора на схват манипулятора через замкнутую обратную кинематику и кодирует параллельный захват единственным вектором большой–указательный палец; Bunny-VisionPro и ACE принимают ту же декомпозицию, причём ACE дополнительно демонстрирует её переносимость между антропоморфными кистями, параллельными схватами и четвероногими роботами.

Методологическую поддержку ослаблению веса запястья даёт абляционное исследование Xin и соавторов, которые собирают всеобъемлющий функционал ретаргетинга — глобальная поза кисти, общая форма кисти, относительные положения кончиков пальцев, ориентации кончиков пальцев — и удаляют члены по одному. Они обнаруживают, что точное отслеживание глобальной позы запястья часто избыточно и способно ухудшать точность по кончикам пальцев, и заменяют позиционную цель по запястью целью по кончику большого пальца, регу-

ляризуя ориентацию запястья лишь слабо. Для представления «запястье плюс захват» отсюда следует, что цель по запястью должна входить в оптимизацию как взвешенная мягкая задача, а не как жёсткое ограничение.

2.2. Формулировки ретаргетинга

Преобладающая современная формулировка ставит ретаргетинг как задачу условных нелинейных наименьших квадратов или квадратичного программирования по конфигурации робота на каждом шаге, минимизируя взвешенную сумму члена соответствия данным и члена временной гладкости при ограничениях на пределы суставов. AnyTeleop даёт каноническую реализацию: целевая функция суммирует по ключевым точкам квадрат невязки между масштабированным вектором ключевой точки человека и соответствующим вектором прямой кинематики робота, плюс штраф первого порядка на изменение конфигурации между соседними кадрами.

Два уточнения непосредственно релевантны настоящей работе. Первое — покадровое взвешивание членов: в формулировке Open-TeleVision невязка каждой ключевой точки масштабируется переключающим весом, зависящим от расстояния и возрастающим при обнаружении щипкового захвата. Механизм в точности аналогичен взвешиванию по покадровой достоверности восприятия. Второе — гладкость второго порядка: DexFlow дополняет стандартный функционал динамическим весом сглаживания и регуляризацией гесссиана для обеспечения C^2 -непрерывности, штрафует кривизну, а не только скорость. Робастификация функцией потерь Хьюбера на члене данных даёт механизм отбраковки выбросов восприятия внутри оптимизатора, а не сглаживания их заранее.

Последовательная схема — фильтрация наблюдаемой траектории в пространстве задачи, покадровое решение обратной кинематики, фильтрация выхода в пространстве суставов — остаётся распространённой в офлайн-пайплайнах. Её дефект структурный, а не эмпирический: фильтрация применяется в пространстве задачи, тогда как требование гладкости относится к траектории суставов, и, поскольку прямая кинематика нелинейна, гладкий декартов вход не влечёт гладкого выхода в пространстве суставов, особенно вблизи сингулярностей. В единой функциональной постановке штраф гладкости действует непосредственно на конфигурацию, поэтому гладкость в пространстве суставов достигается по построению.

2.3. Представление задачи

Объектно-центричные представления доминируют в недавних работах по обобщению между окружениями и эмбодиментами. ORION представляет задачу как трёхмерную траекторию объекта относительно начального и конечного положений объекта, утверждая, что это обоб-

щается на смену визуального фона, сдвиг камеры, пространственную раскладку и новые экземпляры объектов, и что полная реконструкция тела демонстратора не требуется. SPOT кодирует задачу как SE(3)-траекторию позы объекта относительно цели именно с целью развязать эмбодимент-специфичные действия от сенсорного входа, что позволяет обучаться на демонстрациях без действий. Подходы на основе потока приводят эквивалентный аргумент, ослабляя при этом предположение о жёсткости объекта.

Компромисс состоит в том, что объектно-центричные представления требуют устойчивой оценки позы или сегментации объекта, а варианты на основе траектории позы предполагают жёсткость, тогда как траектории в мировой системе координат проще, но привязаны к раскладке сеанса записи. Хранение обоих представлений переносит выбор на потребителя данных при пренебрежимой стоимости хранения.

2.4. Калибровка, слияние и синхронизация мультикамерного RGB-D рига

Доска ChArUco сочетает субпиксельную точность углов шахматной доски с устойчивой идентификацией и толерантностью к окклюзии, свойственными маркерам ArUco. Доска 6×8 даёт до тридцати пяти углов на вид против четырёх у одиночного маркера AprilTag и остаётся детектируемой при частичной окклюзии и на границе кадра. Типичные ошибки репроекции для калибровки ChArUco и ArUco лежат ниже половины пикселя. Маркеры AprilTag проще детектируются на больших дистанциях и при наклонном падении и достаточны для оценки только внешних параметров, но плохо подходят для калибровки внутренних параметров из-за малого числа углов.

Romeo и соавторы дают наиболее чистое прямое сравнение процедур калибровки для мульти-Kinect ригов, сообщая, что трёхмерные процедуры превосходят двумерные подходы на основе шахматной доски: средние расстояния между соответствующими точками облаков составили 21,4 мм при цветовом разрешении и 9,9 мм при инфракрасном для статичной сцены и, соответственно, 20,9 мм и 7,4 мм для динамичной. Ви и Lee сообщают — что важно для геометрии рига, — что уточнение методом итеративной ближайшей точки не сходится для почти противоположных ракурсов камер из-за недостаточного перекрытия облаков точек.

Спецификации одиночных сенсоров ограничивают достижимую точность снизу. Azure Kinect DK специфицирован стандартным отклонением случайной ошибки не более 17 мм и типичной систематической ошибкой ниже 11 мм плюс 0,1 % дистанции; независимые оценки подтверждают эти значения. Практическое следствие состоит в том, что между откалиброванными видами следует ожидать согласования сантиметрового, а не миллиметрового уровня.

Наивное усреднение перекрывающихся измерений глубины уступает взвешенному по достоверности слиянию. Взвешивание по дистанции и по углу между нормалью поверхности и

направлением наблюдения — так, что поверхности, наблюдаемые близко к перпендикуляру, вносят больший вклад, чем наблюдаемые под скользящим углом, — является устоявшейся практикой.

Ловушка для гетерогенного рига состоит в том, что аппаратные часы устройств разных семейств взаимно несопоставимы, поскольку каждое считает собственные циклы от собственной эпохи. Документированная практика для таких ригов — маркировать каждый поступающий кадр единым host-side монотонным таймстампом и выравнивать потоки по ближайшему соседу в этом общем домене, принимая точность миллисекундного масштаба. Поскольку триггеры Azure Kinect и RealSense взаимно несовместимы, это единственный доступный механизм выравнивания двух семейств.

2.5. Позиционирование предлагаемой системы

Сравнение проводится по шести критериям, совместно определяющим предлагаемую архитектуру: (K1) пассивный безмаркерный захват без телеоперационного оборудования; (K2) мультикамерное метрически откалиброванное RGB-D зондирование; (K3) объектно-центричное плотное траекторное представление; (K4) ретаргетинг как единый взвешенный по достоверности функционал стоимости; (K5) экспорт датасета, готового к имитационному обучению; (K6) физическое воспроизведение для валидации датасета до экспорта.

Ни одна из обнаруженных систем не удовлетворяет всем шести критериям одновременно. HOWTransfer ближе всего по последовательности операций, удовлетворяя K1 и K6, однако является кисте-центричной, а не объектно-центричной, использует откалиброванную стереопару RGB вместо метрического RGB-D и не применяет единый функционал стоимости. Vi-RoIL ближе всего по представлению, удовлетворяя K3, но восстанавливает метрический масштаб из монокулярного вида маркерного куба и оценивается только в симуляции. Пересечение литературы по онлайн-оптимизационному ретаргетингу с литературой по офлайн-генерации объектно-центричных датасетов остаётся незанятым, и именно на него нацелена настоящая работа.

Глава 3

Предлагаемое решение

3.1. Общая структура пайплайна

ViKi — офлайн-пайплайн: демонстрации записываются, обрабатываются и экспортируются отдельными стадиями, без требования выполнения какой-либо стадии на интерактивных частотах. Это осознанный выбор. Ослабление ограничения реального времени, формирующего архитектуру систем телеоперации, допускает глобальную оптимизацию по целым траекториям, итеративное уточнение и стадию валидации, исполняемую на физическом оборудовании, — ни одно из этих средств недоступно онлайн-системе.

Пайплайн состоит из шести стадий: захват синхронизированных RGB-D потоков; восприятие с детекцией ключевых точек кисти, подъёмом в три измерения по данным глубины и слиянием видов со взвешиванием по достоверности; представление траектории запястья относительно объекта и относительно якоря рабочей области; ретаргетинг путём минимизации единого взвешенного функционала при кинематических и коллизионных ограничениях; валидация воспроизведением на физическом манипуляторе; экспорт в LeRobot-совместимом формате.

3.2. Калибровка и синхронизация

Внутренние параметры всех цветовых и глубинных потоков оцениваются по наблюдениям доски ChArUco. Внешняя калибровка следует принципу якоря рабочей области: вместо выражения камер друг относительно друга каждая камера калибруется относительно доски ChArUco, жёстко закреплённой в рабочей области и задающей общую мировую систему координат. Привязка к рабочей области, а не к опорной камере, имеет два следствия: добавление или перемещение камеры не аннулирует калибровку остальных, а база манипулятора может быть зарегистрирована в ту же систему координат без отдельной цепочки камера–камера.

Две камеры Azure Kinect синхронизируются аппаратно в конфигурации ведущий/ведомый,

причём ведомые устройства запускаются раньше ведущего, а экспозиции глубины разносятся во избежание взаимной засветки лазеров. Камера RealSense не может разделять этот триггер. Межсеме́йственное выравнивание поэтому использует единый host-side монотонный тайм-стамп, присваиваемый каждому кадру при поступлении, с последующим сопоставлением потоков по ближайшему соседу. Подчеркнём два момента: аппаратные таймстампы устройств не используются для межустройственной арифметики, а монотонные часы применяются вместо часов реального времени, поскольку последние могут быть скачкообразно скорректированы службой синхронизации времени, что испортило бы вычисление интервалов посреди записи.

3.3. Слияние со взвешиванием по достоверности

Оценки от нескольких видов объединяются взвешенным по достоверности усреднением, а не наивным средним. Вес каждой ключевой точки в каждом виде образуется произведением четырёх факторов: оценки видимости детектора; достоверности или флага валидности глубины сенсора в соответствующем пикселе; обратного квадрата дальности; и косинуса угла падения, отсечённого снизу нулём. Произведённая форма выбрана так, чтобы нуль в любом факторе — недетектированная точка, невалидный пиксель глубины, скользящий ракурс — полностью устранял вклад данного вида, а не просто ослаблял его.

3.4. Ретаргетинг как единый функционал стоимости

Пусть $\mathbf{q}_t \in \mathbb{R}^n$ — конфигурация манипулятора в момент t , а $f(\mathbf{q}_t) \in \text{SE}(3)$ — прямая кинематика схвата. Невязка в пространстве задачи относительно желаемой позы есть логарифмическое отображение ошибки позы, $\mathbf{e}_t(\mathbf{q}_t) = \text{Log}((\mathbf{T}_{E,t}^{R,\text{des}})^{-1}f(\mathbf{q}_t))^\vee \in \mathbb{R}^6$. Ретаргетинг ставится как единая условная задача

$$\min_{\mathbf{q}_{1:T}} \sum_{t=1}^T \left[\omega_t \rho_\delta(\|\mathbf{e}_t(\mathbf{q}_t)\|_\Sigma) + \lambda_v \|\mathbf{q}_t - \mathbf{q}_{t-1}\|^2 + \lambda_a \|\mathbf{q}_t - 2\mathbf{q}_{t-1} + \mathbf{q}_{t-2}\|^2 + \lambda_r \|\mathbf{q}_t - \mathbf{q}_{\text{ref}}\|^2 \right] \quad (3.1)$$

при ограничениях на пределы суставов, пределы скоростей и барьерных функциях коллизий, где ω_t — покадровый вес достоверности восприятия, ρ_δ — функция потерь Хьюбера, а $\lambda_v, \lambda_a, \lambda_r$ — веса штрафов на скорость, ускорение и отклонение от опорной позы.

Покадровый вес агрегирует достоверности ключевых точек, породивших оценку запястья в момент t . Конструкция является офлайн-аналогом переключающих весов, зависящих от расстояния, применяемых в онлайн-ретаргетинге: кадры, в которых кисть частично окклюдирована или плохо наблюдаема, оказывают пропорционально меньшее влияние на решение, а члены гладкости проводят траекторию через них вместо того, чтобы член данных стягивал её

к ложному наблюдению.

Функция потерь Хьюбера ограничивает влияние грубых выбросов — ошибочно детектированной кисти, провала глубины, переживших взвешивание по достоверности, — на уровне самого члена данных, а не позволяет стадии фильтрации размазать выброс по соседним кадрам. Именно этот механизм заменяет предварительное сглаживание.

Ключевое структурное отличие от последовательной альтернативы состоит в том, что штрафы гладкости действуют на конфигурацию, то есть в том пространстве, где гладкость и требуется, и балансируются против соответствия данным самим решателем, а не применяются вслепую заранее. Компромисс становится явным: на кадрах высокой достоверности вес велик и решение отслеживает наблюдение; на кадрах низкой достоверности доминируют члены гладкости и решение интерполирует.

Задача решается средствами Pink на Pinocchio. Каждый член отображается на взвешенную задачу квадратичного программирования, тогда как ограничения входят как неравенства, а избегание коллизий выражается через барьерные функции управления. Демпфирование Левенберга–Марквардта стабилизирует решение вблизи сингулярностей. Поскольку постановка офлайновая, задача решается по всей траектории, а не покадрово, поэтому член ускорения корректно определён на каждом внутреннем шаге, а решение не стеснено требованием причинности, с которым сталкивается онлайн-решатель.

Динамические фильтры, налагающие модель движения, — такие как фильтр Калмана или расширенный фильтр Калмана, — намеренно не применяются: они вносят априорное предположение о динамике, которое затем переоценивается оптимизатором, а взаимодействие двух априорных предположений трудно охарактеризовать.

3.5. Валидация воспроизведением

Синтезированные траектории исполняются на физическом манипуляторе до финализации датасета. Стадия служит трём целям. Во-первых, отбраковке нереализуемости: траектория может удовлетворять кинематическим ограничениям в модели и всё же отказать на оборудовании из-за пределов отслеживания контроллера, немоделированных коллизий или граничных условий рабочей области. Во-вторых, закрытию разрыва эмбодиментов у источника: проприоцептивные состояния, записанные при воспроизведении, суть те, которых робот действительно достиг, а не те, что предсказал оптимизатор. Экспорт записанных, а не синтезированных состояний означает, что датасет содержит честные пары наблюдение–действие с целевого эмбодимента, — ровно то свойство, которым телеоперационные датасеты обладают по построению, а наивно выведенные из видео — нет. В-третьих, формированию сигнала курации: эпизоды ранжируются по невязке отслеживания при воспроизведении.

Глава 4

Реализация, результаты и обсуждение

4.1. Реализация

Система реализована на Python без слоя робототехнического middleware. Отказ от ROS был осознанным: пайплайн представляет собой систему пакетной обработки данных, а не распределённую систему управления реального времени, и граф узлов, сериализация сообщений и инструментарий сборки, предоставляемые middleware, добавили бы эксплуатационную сложность, не отвечая ни на одно требование офлайн-постановки. Взаимодействие с манипулятором ведётся напрямую через `ur - rtde`.

Реализация разделена на модули захвата, калибровки, восприятия, представления, ретаргетинга, воспроизведения, экспорта и интерфейса. Разделение следует стадиям пайплайна, причём контракт систем координат — каждая пространственная величина несёт явный идентификатор системы координат — обеспечивается на границах модулей, так что ошибки систем координат проявляются как ошибки типов, а не как безмолвные численные ошибки. Система распространяется под лицензией MIT.

4.2. Экспериментальная установка

Эксперименты выполнены на манипуляторе UR3 с параллельным схватом, двух камерах Azure Kinect DK в аппаратной синхронизации ведущий/ведомый и одной Intel RealSense D435i, наблюдающих настольную рабочую область, привязанную доской ChArUco. Расположение камер близко к ортогональному ради сохранения перекрытия полей зрения.

Оценка проводилась на намеренно ограниченном классе задач, выбранном так, чтобы выполнялись квазистатическое предположение и предположение о жёсткости объекта, а успех измерялся однозначно: захват и перенос объекта в отмеченную целевую позицию; то же с объектом, инициализированным в позе, не встречавшейся при демонстрации, для проверки объектно-относительного представления; переливание, проверяющее точность по ориен-

тации, а не только по положению.

Предлагаемая формулировка сравнивается с последовательной базовой схемой, а также с абляциями, каждая из которых отличается от полной системы ровно одним компонентом: без взвешивания по достоверности; без члена ускорения; без робастификации Хьюбера; с представлением в мировой системе координат вместо объектно-относительного.

4.3. Метрики

Метрики зафиксированы до финальных прогонов, чтобы критерии успеха не подбирались после наблюдения результатов. Точность ретаргетинга измеряется среднеквадратичной ошибкой отслеживания в пространстве задачи, отдельно по трансляции и вращению. Гладкость измеряется спектральной длиной дуги профиля скоростей суставов — безразмерной мерой, инвариантной к амплитуде и длительности, — вместе со средним модулем рывка. Реализуемость измеряется долей синтезированных эпизодов, исполняемых на оборудовании без отказа контроллера, нарушения пределов суставов или коллизии. Успешность нижележащих политик измеряется для АСТ и Diffusion Policy, обученных на экспортированном датасете. Точность калибровки измеряется ошибкой репроекции, межкамерной ошибкой регистрации и остаточным рассогласованием таймстампов между семействами устройств.

4.4. Результаты

[Раздел заполняется по завершении экспериментов.]

Предварительно ожидается, что предлагаемая формулировка снизит ошибку отслеживания позы запястья на **XX %** и повысит гладкость в пространстве суставов на **XX %** относительно последовательной базовой схемы, что отбор по результатам воспроизведения отклонит **XX %** эпизодов как нереализуемые, а политики, обученные на полученном датасете, достигнут успешности **XX %**.

4.5. Декомпозиция ошибки

Методологическое обязательство настоящей работы состоит в том, что остаточная ошибка декомпозируется, а не сообщается единой агрегированной величиной. Три вклада независимы по происхождению и требуют разных мер; их смешение сделало бы агрегат неинформативным относительно того, что именно следует улучшать.

Шум детекции ключевых точек — ошибка в положениях ключевых точек кисти на плоскости изображения, распространяемая через подъём по глубине. Этот вклад снижается взве-

шиванием по достоверности и мультивидовым слиянием и не снижается улучшением калибровки.

Ошибка калибровки — ошибка в преобразованиях камера–рабочая область и робот–рабочая область. Этот вклад систематичен в пределах сеанса, проявляется как постоянное смещение, а не как шум, и не снижается мультивидовым слиянием, поскольку все виды его наследуют.

Представленческая зависимость — ошибка, вносимая выбором системы отсчёта, в частности чувствительность траекторий в мировой системе координат к смещению объекта. Этот вклад равен нулю, когда объект находится там же, где при демонстрации, и растёт со смещением.

4.6. Ограничения

Бинарное состояние захвата не способно представлять внутрикистевую манипуляцию, перехват или захваты с модуляцией усилия. Объектно-относительное преобразование не определено для деформируемых объектов, что исключает манипуляцию тканью, кабелем и сыпучими средами. Объектно-относительное представление наследует ошибку оценщика позы объекта и при его отказе — на бестекстурных, симметричных или окклюдированных объектах — деградирует хуже той альтернативы в мировой системе координат, которую призвано улучшить. Силы и контактная динамика не оцениваются, поэтому успех на задачах с компонентой регулирования усилия не заявляется. Оценка использует одного демонстратора и ограниченный класс задач, поэтому обобщение по демонстраторам, морфологиям кисти и семействам задач не установлено. Наконец, согласование между камерами на сантиметровом уровне ограничивает достижимую точность независимо от формулировки ретаргетинга.

Глава 5

Выводы

Работа рассмотрела вопрос о том, каким образом демонстрации манипуляции, записанные пассивно, могут быть преобразованы в датасеты, пригодные для обучения визуомоторных имитационных политик. Показано, что два устоявшихся подхода к этой задаче по отдельности неполны: системы онлайн-телеоперации сошлись к методологически корректной формулировке ретаргетинга — единому взвешенному функционалу стоимости, — но не порождают датасета, тогда как офлайн-пайплайны порождают датасеты, но выполняют ретаргетинг либо вовсе не выполняя его, через разреженные ключевые кадры объекта, либо через последовательную схему фильтрация–решение–фильтрация, сглаживание в которой применяется не в том пространстве, где требуется гарантируемое ею свойство.

Предложена система ViKi, занимающая пересечение этих подходов. Она захватывает демонстрации метрически откалиброванным мультикамерным RGB-D ригом, привязанным к системе координат рабочей области по доске ChArUco; представляет кисть минимально — позой запястья в $SE(3)$ с бинарным состоянием захвата; хранит каждую демонстрацию и относительно манипулируемого объекта, и относительно якоря рабочей области; выполняет ретаргетинг минимизацией единого взвешенного функционала, в котором член данных масштабируется покадровой достоверностью восприятия и робастифицируется функцией Хьюбера, а штрафы на скорость и ускорение действуют непосредственно в пространстве суставов; валидирует результат исполнением на физическом манипуляторе до экспорта; и записывает LeRobot-совместимый датасет, содержащий проприоцепцию, которой робот действительно достиг, а не состояния, предсказанные оптимизатором.

Следует отдельно указать, что *не* заявляется. Функционал стоимости не нов как оператор; его компоненты присутствуют в предшествующих работах, и заявление об алгоритмической новизне было бы опровергнуто этим prior art. Объектно-центричное представление, привязка по ChArUco, взвешенное по достоверности слияние глубины и синхронизация по монотонным часам хоста — устоявшиеся практики. Вклад состоит в конъюнкции и переносе режима, которые проведённый анализ предшествующих работ обнаружил незанятыми.

Примечание: величины и утверждения, выделенные этим цветом, подлежат заполнению или проверке по завершении экспериментальной части. Полный список источников приведён в основном тексте работы на английском языке.