

УНИВЕРСИТЕТ ИННОПОЛИС

Бакалавриат по направлению «Компьютерные науки»

ViKi: кинематическая имитация на основе компьютерного зрения

Краткое изложение — главы 1–3

Автор: **Артём [Фамилия]**

Научный руководитель: **[ФИО]**

Группа: **[группа]**

Иннополис, Россия

2026

Оглавление

1	Постановка задачи и актуальность	2
1.1	Предметная область	2
1.2	Проблема	2
1.3	Научный пробел	3
1.4	Исследовательские вопросы и гипотезы	4
2	Обзор литературы	5
2.1	Как представляют кисть человека	5
2.2	Формулировки ретаргетинга	5
2.3	Представление задачи	6
2.4	Калибровка, слияние и синхронизация RGB-D рига	6
2.5	Место предлагаемой системы	7
3	Предлагаемое решение	8
3.1	Структура пайплайна	8
3.2	Калибровка и синхронизация	8
3.3	Слияние со взвешиванием по достоверности	9
3.4	Ретаргетинг как единый функционал стоимости	9
3.5	Валидация воспроизведением	10

Глава 1

Постановка задачи и актуальность

1.1. Предметная область

Роботов учат новым задачам манипуляции по демонстрациям человека (imitation learning). Чем больше и чище демонстрации, тем лучше работает итоговая политика, например Action Chunking Transformer (ACT) или Diffusion Policy.

Сегодня демонстрации чаще всего собирают *телеоперацией*: человек ведёт робота по траектории задачи, а позы суставов и видео записываются. Плюс в том, что такие данные сразу исполнимы роботом. Минусы: на каждый эпизод уходит реальное время оператора; нужно дорогое и специфичное оборудование (VR-контроллер, экзоскелет, устройство с силовой отдачей); записанное движение определяется не столько задачей, сколько задержками и эргономикой интерфейса.

Пассивная запись обращает этот компромисс: человек выполняет задачу голыми руками, без интерфейса. Это дешево, быстро и естественно — за время одного телеоперационного эпизода демонстратор успевает записать десятки. Но теряется как раз то, что телеоперация гарантирует: нет меток действий, а кинематика руки человека не совпадает с кинематикой робота. Устранение этого несовпадения — задача *ретаргетинга* — и есть тема работы.

1.2. Проблема

Пассивный захват даёт наблюдения, а не действия. Нужно превратить траекторию кисти человека в траекторию суставов робота, которая одновременно: (i) повторяет значимое для задачи движение, (ii) достаточно гладкая для обучения политикой и (iii) физически исполнима на конкретном манипуляторе. Задача недоопределена и осложнена шумом восприятия. Преобладают два режима отказа.

Шум усиливается через кинематическую цепь. Оценка глубины ключевых точек кисти шумит на масштабе сантиметров. Обратная кинематика нелинейна, поэтому малое воз-

мушение в пространстве задачи вблизи сингулярности отображается в большое отклонение в пространстве суставов. Привычный ответ — сгладить наблюдаемую траекторию до решения обратной кинематики и сгладить траекторию суставов после — не помогает: сглаживание применяется в пространстве задачи, а гладкость нужна в пространстве суставов, и вдобавок вместе с шумом удаляется истинное быстрое движение.

Зависимость от представления. Если хранить траекторию как абсолютные позиции в системе координат камеры или мира, она привязана к раскладке конкретного сеанса записи. Сдвинули объект — траектория неверна; сменили робота — неверна иначе. Обобщается отношение «кисть–объект», а не абсолютный путь кисти в пространстве.

1.3. Научный пробел

У обоих режимов отказа есть известные решения, но они приняты в разных, почти не пересекающихся сообществах.

Оптимизационный ретаргетинг — когда точность соответствия данным, гладкость во времени и ограничения на суставы ставятся как одна задача условной оптимизации по конфигурации робота — стал стандартом в системах *онлайн-телеоперации*. Каноническую форму задали AnyTeleop и библиотека dex - retargeting; на них опираются Open-TeleVision, Bunny-VisionPro, ACE; DexFlow расширяет штраф гладкости до второго порядка. Но человек всегда остаётся в контуре, оптимизация идёт на интерактивных частотах, и датасет не формируется.

Офлайн-пайплайны, делающие датасеты из пассивного видео человека, берут объектно-центричные представления, но не единую оптимизационную постановку. ORION планирует по разреженным ключевым кадрам объекта и покадровый ретаргетинг кисти не выполняет вовсе. OKAMI восстанавливает модель тела и кисти и ретаргетит в две развязанные стадии — варпинг референсной траектории под новое положение объекта, затем решение обратной кинематики, — то есть ту самую последовательную схему, которую критикуют выше.

Целевой анализ литературы не нашёл системы, объединяющей сразу: пассивный безмаркерный захват; метрически откалиброванный мультикамерный RGB-D риг; объектно-центричное плотное траекторное представление; ретаргетинг как единый функционал стоимости; экспорт готового к обучению датасета; и физическое воспроизведение как этап валидации до экспорта. Ближайшие системы закрывают часть критериев и не закрывают остальные. Пробел, таким образом, не в новом операторе ретаргетинга, а в переносе устоявшейся формулировки в режим, где её не применяли, вместе с нужной этому режиму сенсорной и валидационной инфраструктурой.

1.4. Исследовательские вопросы и гипотезы

Основной вопрос. Как демонстрации манипуляции, захваченные пассивно откалиброванным мультикамерным RGB-D ригом, ретаргетить на робота так, чтобы получать датасеты для обучения визуомоторных имитационных политик?

- ИВ1.** Как единый взвешенный функционал стоимости (член соответствия данным со взвешиванием по достоверности плюс штрафы на скорость и ускорение) влияет на точность и гладкость траекторий суставов по сравнению с последовательной схемой smooth-IK-smooth?
- ИВ2.** Какая точность позы запястья достижима при взвешенном по достоверности слиянии нескольких откалиброванных RGB-D видов с общим началом координат по доске ChArUco, и как раскладывается остаточная ошибка?
- ИВ3.** Насколько воспроизведение синтезированных траекторий на реальном манипуляторе до экспорта повышает исполнимость датасета?

Гипотезы.

- **Г1.** Единый взвешенный функционал даёт меньшую ошибку слежения в пространстве задачи и большую гладкость суставов, чем схема smooth-IK-smooth, на тех же демонстрациях.
- **Г2.** Взвешивание члена данных по покадровой достоверности восприятия снижает ошибку слежения относительно равномерного взвешивания, сильнее — на кадрах с частичной окклюзией кисти.
- **Г3.** Отбор траекторий по результатам воспроизведения до экспорта повышает долю эпизодов, исполнимых на роботе.

Вопросы проверены по критериям FINER: *выполнимы* (оборудование, решатель и протокол доступны, класс задач намеренно узкий); *интересны* и *релевантны* (стоимость демонстраций — признанное узкое место); *новы* в смысле переноса режима, а не нового оператора; *этичны* — испытуемых, кроме автора, нет, персональные данные не сохраняются.

Глава 2

Обзор литературы

2.1. Как представляют кисть человека

Часть работ восстанавливает полную кинематику демонстратора: OKAMI (SMPL-H для тела и MANO для кисти), DexCanvas (подгонка MANO к данным 22 ИК-камер захвата движения и двух RGB-D сенсоров), DexMV (MANO вместе с позой объекта). Полная реконструкция богата и нужна для многопальцевых антропоморфных кистей, но тянет тяжёлый перцептивный стек и добавляет плохо измеримую ошибку — подгонку меша. Для параллельного схвата большая часть этого богатства всё равно отбрасывается.

Здесь кисть представлена минимально: поза запястья в $SE(3)$ плюс бинарное состояние захвата (открыт/закрыт). Так делает магистральное направление телеоперации — Open-TeleVision, Bunny-VisionPro, ACE. Абляции Xin и соавт. (полный функционал ретаргетинга, из которого члены удаляют по одному) показывают, что точное слежение за глобальной позой запястья часто избыточно и даже вредит точности по кончикам пальцев. Отсюда: цель по запястью должна входить в оптимизацию как взвешенный мягкий член, а не жёсткое ограничение.

2.2. Формулировки ретаргетинга

Преобладающая современная формулировка ставит ретаргетинг как условную задачу (нелинейный МНК или квадратичное программирование) по конфигурации робота на каждом кадре: минимум взвешенной суммы члена соответствия данным и члена гладкости при ограничениях на пределы суставов. Каноническая реализация — AnyTeleop.

Два уточнения важны для настоящей работы. Первое — покадровое взвешивание членов: в Open-TeleVision невязка каждой ключевой точки масштабируется весом, зависящим от расстояния; это прямой аналог взвешивания по достоверности восприятия. Второе — гладкость второго порядка: DexFlow штрафует кривизну, а не только скорость. Робастная потеря Хьюбера на члене данных отбраковывает выбросы восприятия внутри оптимизатора, а не сглаживает

их заранее.

Последовательная схема — сгладить наблюдаемую траекторию, покадрово решить обратную кинематику, сгладить выход в пространстве суставов — распространена в офлайне. Её дефект структурный: сглаживание идёт в пространстве задачи, а гладкость нужна в пространстве суставов; из-за нелинейности прямой кинематики гладкий вход не даёт гладкого выхода, особенно у сингулярностей. В едином функционале штраф гладкости действует прямо на конфигурацию.

2.3. Представление задачи

Объектно-центричные представления доминируют в недавних работах про обобщение между сценами и роботами. ORION задаёт задачу как 3D-траекторию объекта относительно его начального и конечного положений и утверждает, что это устойчиво к смене фона, сдвигу камеры и новым экземплярам объекта. SPOT кодирует задачу как $SE(3)$ -траекторию позы объекта относительно цели, чтобы отвязать действия от сенсорного входа. Подходы на основе потока дают тот же аргумент без предположения о жёсткости объекта.

Компромисс: объектно-центричные представления требуют устойчивой оценки позы или сегментации объекта, а траектории в мировой системе координат проще, но привязаны к раскладке съёмки. ViKi хранит оба представления — выбор остаётся за потребителем данных, а стоимость хранения мала.

2.4. Калибровка, слияние и синхронизация RGB-D рига

Доска ChArUco сочетает субпиксельную точность углов шахматной доски с устойчивым распознаванием маркеров ArUco. Доска 6×8 даёт до 35 углов на вид, остаётся детектируемой при частичной окклюзии и на краю кадра; типичная ошибка репроекции — ниже половины пикселя.

Romeo и соавт. дают чистое сравнение процедур калибровки мульти-Kinect ригов: трёхмерные процедуры точнее двумерных на основе шахматной доски (расхождения облаков точек порядка 10–21 мм). Ву и Lee отмечают, что уточнение методом итеративной ближайшей точки не сходится для почти противоположных ракурсов из-за малого перекрытия облаков.

Сами сенсоры ограничивают точность снизу: Azure Kinect DK специфицирован случайной ошибкой не более 17 мм и систематической ниже 11 мм плюс 0,1 % дистанции. Практический вывод: между откалиброванными видами следует ожидать согласования сантиметрового, а не миллиметрового уровня.

Перекрывающиеся измерения глубины лучше объединять не наивным средним, а взвешенным по достоверности: вклад тем больше, чем ближе точка и чем ближе к перпендикуляру

наблюдается поверхность.

Часы камер разных семейств несопоставимы. Документированная практика — метить каждый входящий кадр единым монотонным таймстампом хоста и выравнивать потоки по ближайшему соседу в этом общем домене (точность миллисекундного масштаба). Триггеры Azure Kinect и RealSense несовместимы, поэтому другого механизма выравнивания двух семейств нет.

2.5. Место предлагаемой системы

Сравнение — по шести критериям, которые вместе задают архитектуру: (K1) пассивный безмаркерный захват без телеоперационного оборудования; (K2) мультикамерное метрически откалиброванное RGB-D зондирование; (K3) объектно-центричное плотное траекторное представление; (K4) ретаргетинг как единый взвешенный по достоверности функционал стоимости; (K5) экспорт датасета для имитационного обучения; (K6) физическое воспроизведение для валидации до экспорта.

Ни одна найденная система не закрывает все шесть. HOWTransfer ближе всего по порядку операций (K1, K6), но кисте-центрична, использует стереопару RGB вместо метрического RGB-D и не применяет единый функционал. Vi-RoIL ближе по представлению (K3), но восстанавливает масштаб из монокулярного вида маркерного куба и проверяется только в симуляции. Пересечение онлайн-оптимизационного ретаргетинга и офлайн-генерации объектно-центричных датасетов пусто — на него и нацелена работа.

Глава 3

Предлагаемое решение

3.1. Структура пайплайна

ViKi — офлайн-пайплайн: запись, обработка и экспорт идут отдельными стадиями, и ни одна не обязана работать в реальном времени. Это осознанный выбор: без ограничения реального времени можно оптимизировать сразу по всей траектории, итеративно уточнять и добавить стадию проверки на реальном оборудовании.

Стадий шесть:

1. захват синхронизированных RGB-D потоков;
2. восприятие — детекция ключевых точек кисти, подъём в 3D по данным глубины, слияние видов со взвешиванием по достоверности;
3. представление траектории запястья относительно объекта и относительно якоря рабочей области;
4. ретаргетинг — минимизация единого взвешенного функционала при кинематических и коллизионных ограничениях;
5. валидация воспроизведением на физическом манипуляторе;
6. экспорт в формате, совместимом с LeRobot.

3.2. Калибровка и синхронизация

Внутренние параметры всех цветовых и глубинных потоков оцениваются по наблюдениям доски ChArUco. Внешняя калибровка следует принципу *якоря рабочей области*: каждая камера калибруется относительно доски ChArUco, жёстко закреплённой в рабочей области и

задающей общую мировую систему координат, — а не относительно опорной камеры. Следствия: добавление или перемещение камеры не аннулирует калибровку остальных, а базу манипулятора можно привязать к тем же координатам без отдельной цепочки камера–камера.

Две камеры Azure Kinect синхронизируются аппаратно в режиме ведущий/ведомый: ведомые запускаются раньше ведущего, а экспозиции глубины разнесены во времени, чтобы лазеры не засвечивали друг друга. RealSense этот триггер не поддерживает, поэтому между семействами используется единый монотонный таймстамп хоста на каждый кадр с последующим сопоставлением по ближайшему соседу. Часы берутся монотонные, а не реального времени: последние может скачком поправить служба синхронизации времени и испортить вычисление интервалов посреди записи.

3.3. Слияние со взвешиванием по достоверности

Оценки от нескольких видов объединяются взвешенным средним. Вес каждой ключевой точки в каждом виде — произведение четырёх множителей: оценки видимости детектора; валидности глубины сенсора в соответствующем пикселе; обратного квадрата дальности; косинуса угла падения, отсечённого снизу нулём. Форма выбрана так, чтобы ноль в любом множителе — точка не найдена, пиксель глубины невалиден, скользящий ракурс — полностью убирал вклад этого вида, а не просто ослаблял его.

3.4. Ретаргетинг как единый функционал стоимости

Пусть $\mathbf{q}_t \in \mathbb{R}^n$ — конфигурация манипулятора в момент t , а $f(\mathbf{q}_t) \in \text{SE}(3)$ — прямая кинематика схвата. Ошибка в пространстве задачи относительно желаемой позы — логарифм ошибки позы, $\mathbf{e}_t(\mathbf{q}_t) = \text{Log}((\mathbf{T}_{E,t}^{R,\text{des}})^{-1}f(\mathbf{q}_t))^\vee \in \mathbb{R}^6$. Ретаргетинг ставится как одна условная задача:

$$\min_{\mathbf{q}_{1:T}} \sum_{t=1}^T \left[\omega_t \rho_\delta(\|\mathbf{e}_t(\mathbf{q}_t)\|_\Sigma) + \lambda_v \|\mathbf{q}_t - \mathbf{q}_{t-1}\|^2 + \lambda_a \|\mathbf{q}_t - 2\mathbf{q}_{t-1} + \mathbf{q}_{t-2}\|^2 + \lambda_r \|\mathbf{q}_t - \mathbf{q}_{\text{ref}}\|^2 \right] \quad (3.1)$$

при ограничениях на пределы суставов и скоростей и с барьерными функциями коллизий. Здесь ω_t — покадровый вес достоверности восприятия, ρ_δ — потеря Хьюбера, $\lambda_v, \lambda_a, \lambda_r$ — веса штрафов на скорость, ускорение и отклонение от опорной позы.

Вес ω_t собирается из достоверностей ключевых точек, породивших оценку запястья в момент t . На плохо наблюдаемых кадрах он мал, и траекторию через них проводят члены гладкости, а не член данных, стягивающий её к ложному наблюдению. Потеря Хьюбера ограничивает влияние грубых выбросов прямо в члене данных — это и заменяет предварительное сглажи-

вание.

Ключевое отличие от последовательной схемы: штрафы гладкости действуют на конфигурацию, то есть в том пространстве, где гладкость и нужна, и балансируются против соответствия данным самим решателем. На кадрах высокой достоверности вес велик и решение отслеживает наблюдение; на кадрах низкой доминируют члены гладкости и решение интерполирует.

Задача решается средствами Pink на Pinocchio: каждый член — взвешенная QP-задача, ограничения входят как неравенства, избегание коллизий — через барьерные функции, а демпфирование Левенберга–Марквардта стабилизирует решение у сингулярностей. Так как режим офлайн, задача решается по всей траектории, а не покадрово: член ускорения корректно определён на каждом внутреннем шаге, а решение не стеснено требованием причинности.

Динамические фильтры, налагающие модель движения (фильтр Калмана и подобные), намеренно не применяются: они вносят априорное предположение о динамике, которое затем переоценивает оптимизатор, а взаимодействие двух априоров трудно охарактеризовать.

3.5. Валидация воспроизведением

Синтезированные траектории исполняются на физическом манипуляторе до финализации датасета. Стадия служит трём целям:

1. *Отсев неисполнимого.* Траектория может удовлетворять кинематическим ограничениям в модели и всё же отказать на оборудовании — из-за пределов отслеживания контроллера, немоделированных коллизий или границы рабочей области.
2. *Закрытие разрыва эмбодиментов у источника.* Записываются проприоцептивные состояния, которых робот действительно достиг, а не предсказанные оптимизатором. Экспорт именно записанных состояний даёт честные пары «наблюдение–действие» с целевого робота.
3. *Сигнал для курации.* Эпизоды ранжируются по невязке отслеживания при воспроизведении.